# 《大数据技术》

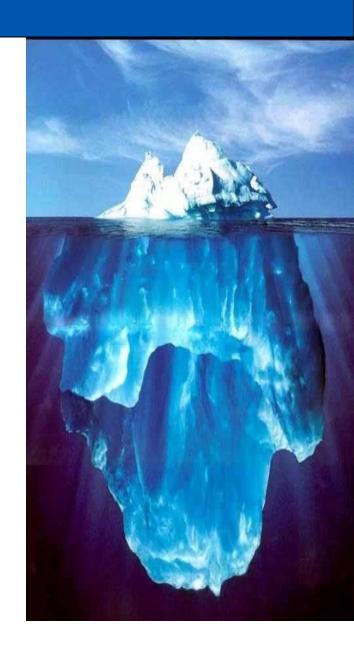
# 第三章 Hadoop系统安装运行

孙鹏飞

E-mail: sunpengfei@bupt.edu.cn

### 提纲

- 1.1 单机Hadoop系统安装步骤
- 1.2 集群Hadoop系统安装步骤
- 1.3 Hadoop集群作业提交与执行



# Hadoop系统运行的软件环境

· Linux操作系统

如RHELS 6.0 (Red Hat Enterprise Linux Server 6.0)

- 直接安装Linux
- Window下安装Linux虚拟机
- SSH (Secure Shell)

主要用于远程管理Hadoop节点以及Hadoop节点间 的安全共享访问

Java

如Java1.6.0

# Hadoop系统的安装方式

#### - 单机方式

在一台运行Linux或Windows下虚拟Linux的单机上安装运行 Hadoop系统

#### - 单机伪分布方式

在一台运行Linux或Window下虚拟Linux的单机上,用伪分布方式,用不同的java进程模拟分布运行中的NameNode、DataNode、JobTracker、TaskTracker等各类节点

#### - 集群分布模式

在一个真实的集群环境下安装运行Hadoop系统,集群的每个 节点可以运行Linux或Window下的虚拟Linux。

单机和伪分布模式下编写调试完成的程序不需修改即可在真实的分布式Hadoop集群下运行

- 安装JDK
- 下载安装Hadoop
- 配置SSH
- 配置Hadoop的环境
- 格式化HDFS文件系统
- 启动Hadoop环境
- 运行程序测试
- 查看集群状态

#### 1. 单机操作系统安装

在单机上安装Linux或Window下虚拟Linux, 假设安装后机器名为Siler。

#### 2. 安装SSH

如果安装RHELS 6.0,确保软件安装时把SSH选上;如果安装Linux时没有安装SSH,则需要另行安装SSH

#### 3. 安装Java

下载和安装Java,将java安装在root/usr/java目录下

#### 4. 创建用户

为Hadoop创建一个专门的用户组如hadoop-user,然后在该用户组下创建不同的用户。可在安装系统的时候创建,也可以在安装好之后用如下命令创建:

[root@Siler ~]# groupadd hadoop-user

[root@Siler ~]# useradd -g hadoop\_user -d /home/hadoop hadoop "hadoop"是所创建的用户名, -d指明" hadoop"用户的home目录是 /home/hadoop)

[root@Siler ~]# passwd hadoop [给用户hadoop设置口令]

#### 5. 解压安装Hadoop

- 到Hadoop官网下载hadoop-0.21.0.tar.gz
- 建立安装目录
  - [hadoop@Siler ~] mkdir ~/hadoop\_installs
- 把hadoop-0.21.0.tar.gz放在这里,然后解压:

[hadoop@Siler hadoop\_installs]\$ tar -zxvf hadoop-0.21.0.tar.gz

#### 6. 配置环境变量

- 进入到 "hadoop"用户下
  [root@Siler ~]# su hadoop [注意中间的"-"不要丢]
  [hadoop@Siler ~]\$
- 编辑~/.bash\_profile文件(用vi 或gedit)vi ~/.bash\_profile
- 设置如下环境变量:

```
PATH=$PATH:$HOME/bin export JAVA_HOME=/usr/java/java-1.6.0 export HADOOP_HOME=/home/hadoop/hadoop_installs/hadoop-0.21.0 export PATH=$PATH:$JAVA_HOME/bin:$HADOOP_HOME/bin export CLASSPATH=$JAVA_HOME/lib:.
```

#### 7. 免密码SSH访问配置

在伪分布模式下(集群分布模式更需要这个设置过程),为了实现免密码SSH登陆连接,需要进行相应的配置。方式是创建一个认证文件,然后用public key实现免密码的登录连接。过程如下:

- 执行命令产生认证文件
  - [hadoop@Siler ~]\$ ssh -keygen -t rsa -P ""
  - 一直敲回车,然后将在/home/hadoop/.ssh目录下生成id\_rsa认证 文件
- 将该文件复制到名为authorized\_keys的文件
  [hadoop@Siler ~] cat ~/.ssh/id\_rsa.pub >> ~/.ssh/authorized\_keys
- 然后测试一下看看能不能登录: [hadoop@Siler ~] ssh localhost

#### 什么是SSH?

- SSH(Secure Shell),是建立在应用层和传输层基础上的安全协议。
- 传统的网络服务程序,如FTP、POP和Telnet本质上都是不安全的;它们在网络上用明文传送数据、用户帐号和用户口令,很容易受到中间人(man-in-the-middle)攻击方式的攻击。
- 而SSH是目前较为可靠的、专为远程登录会话和其他网络服务提供安全性的协议。利用SSH协议可以有效防止远程管理过程中的信息泄露问题。通过SSH可以对所有传输的数据进行加密,也能够防止DNS欺骗和IP欺骗。
- SSH另一项优点是其传输的数据是经过压缩的,所以可以加快传输的速度。SSH有很多功能,它既可以代替Telnet,又可以为FTP、POP、PPP提供一个安全的登陆会话"通道"。
- Hadoop使用SSH保证在远程管理Hadoop节点和节点间用户共享访问时的安全性。

### 8. 修改hadoop配置文件

Hadoop的配置文件存放在hadoop安装目录下的conf目录中 ,主要有以下几个配置文件要修改:

- conf/hadoop-env.sh: Hadoop环境变量设置
- conf/core-site.xml: 主要完成NameNode的IP和端口设置
- conf/hdfs-site.xml:主要完成HDFS的数据块副本等参数设置
- conf/mapred-site.xml: 主要完成JobTracker IP和端口设置

#### 9.格式化NameNode

• 执行Hadoop的bin文件夹中的格式化命令:

[hadoop@Siler ~]\$ hadoop namenode -format

如果格式化成功,会返回一堆有关NameNode的启动信息, 其中会有一句"…. has been successfully formatted."

#### 10. 启动HDFS和MapReduce

 执行以下命令启动HDFS和MapReduce [hadoop@Siler ~]\$ start-all.sh

 用JPS命令检查一下是否正常启动: [hadoop@Siler ~]\$ jps

#### 显示以下各进程信息则说明HDFS和MapReduce都已正常 启动:

4706 JobTracker 4582 SecondaryNameNode 4278 NameNode 4413 DataNode 4853 TaskTracker 4889 Jps

#### 11. 停止HDFS和MapReduce

 执行以下命令启动HDFS和MapReduce [hadoop@Siler~]\$ stop-all.sh

#### 12. 运行测试

• 在Linux文件系统下(如/root/test)创建两个文本数据文件:

file1.txt: hello hadoop hello world

file2.txt: goodbye hadoop

• 将文件复制到HDFS文件系统中:

[hadoop@Siler ~]\$ dfs -copyFromLocal /root/test test-in

test-in是在HDFS中建立的一个数据数据目录

运行hadoop安装包中自带的WordCount程序进行测试:

[hadoop@Siler ~]\$ hadoop jar hadoop-0.21.0-examples.jar wordcount test-in test-out

其中test-out只能由程序创建,不能事先存在

#### 1. 操作系统安装

在每个节点上安装Linux或Window下虚拟Linux, 假设安装后机器名为Master。

#### 2. 安装SSH

如果安装RHELS 6.0,确保软件安装时把SSH选上;如果安装Linux时没有安装SSH,则需要另行安装SSH

#### 3. 安装Java

下载和安装Java,将java安装在root/usr/java目录下

#### 4. 创建用户

为Hadoop创建一个专门的用户组如hadoop-user,然后在该用户组下创建不同的用户。可在安装系统的时候创建,也可以在安装好之后用如下命令创建:

- 1). 在真实集群分布模式下,要求每个节点使用相同的用户名,比如,可以使用"hadoop"作为所有节点上统一的用户名。
- 2). 并且要求在所有节点上安装的hadoop系统具有完全一致的目录结构。

### 5. 在主节点上解压安装Hadoop

- 到Hadoop官网下载hadoop-0.21.0.tar.gz
- 建立安装目录
  - [hadoop@ Master ~] mkdir ~/hadoop\_installs
- 把hadoop-0.21.0.tar.gz放在这里,然后解压:

[hadoop@ Master hadoop\_installs]\$ tar -zxvf hadoop-0.21.0.tar.gz

注:这个过程仅需在主节点上完成,然后安装好的Hadoop系统将被复制到所有从节点

#### 6. 配置环境变量(每个节点都必须做)

- 进入到 "hadoop"用户下
  [root@Siler ~]# su hadoop [注意中间的"-"不要丢]
  [hadoop@Siler ~]\$
- 编辑~/.bash\_profile文件(用vi 或gedit)
   vi ~/.bash\_profile
- 设置如下环境变量:

```
PATH=$PATH:$HOME/bin export JAVA_HOME=/usr/java/java-1.6.0 export HADOOP_HOME=/home/hadoop/hadoop_installs/hadoop-0.21.0 export PATH=$PATH:$JAVA_HOME/bin:$HADOOP_HOME/bin export CLASSPATH=$JAVA_HOME/lib:.
```

#### 7. 免密码SSH访问配置

在真实集群分布模式下更需要这个设置过程,为了实现节点间相互的免密码SSH访问,需要进行相应的配置。方式是创建一个认证文件,然后用public key实现免密码的登录连接。过程如下:

- 执行命令产生认证文件
  - [hadoop@ Master ~]\$ ssh -keygen -t rsa -P ""
  - 敲回车,然后将在/home/hadoop/.ssh目录下生成id\_rsa认证文件
- 将该文件复制为名为authorized\_keys的文件
   [hadoop@ Master ~]\$ cat ~/.ssh/id\_rsa.pub >> ~/.ssh/authorized\_keys
- 将authorized\_keys文件复制到所有节点上

[hadoop@Master ~]\$ scp authorized\_keys

[从节点主机名或IP]:/home/hadoop/.ssh

### 8.在主节点上修改hadoop配置文件

Hadoop的配置文件存放在hadoop安装目录下的conf目录中,主要有以下几个配置文件要修改:

- conf/hadoop-env.sh: Hadoop环境变量设置
- conf/core-site.xml: 主要完成NameNode的IP和端口设置
- conf/hdfs-site.xml:主要完成HDFS的数据块副本等参数设置
- conf/mapred-site.xml: 主要完成JobTracker IP和端口设置
- conf/slaves:完成Slaves节点IP设置

注:这个过程仅需在主节点上进行,然后将随着主机上安装好的Hadoop目录一起复制到所有从节点

在NameNode和DataNode节点上进行主机名和IP解析配置 修改每台机器的/etc/hosts设置:

- 若为NameNode,则需要在hosts文件中添加集群中所有节点的IP
   地址机器对应的主机名
- 若为DataNode,则只需要在文件中添加本机和NameNode的IP地 址及对应的主机名

### 9.复制Hadoop系统

将在主节点安装好的Hadoop系统目录复制到每一个从节点上:

[hadoop@ Master ~]\$ scp -r /home/hadoop/hadoop-installs [从节点主机名或IP]:/home/hadoop/

这样可以避免对每一个从节点重复进行Hadoop系统安装。

#### 10.格式化NameNode

• 执行Hadoop的bin文件夹中的格式化命令:

[hadoop@ Master ~]\$ hadoop namenode -format

如果格式化成功,会返回一堆有关NameNode的启动信息, 其中会有一句"…. has been successfully formatted."

#### 11. 启动HDFS和MapReduce

- 执行以下命令启动HDFS和MapReduce [hadoop@ Master ~]\$ start-all.sh
- 用JPS命令检查一下是否正常启动: [hadoop@ Master ~]\$ jps

### 显示以下各进程信息则说明HDFS和MapReduce都已 正常启动:

4706 JobTracker 4582 SecondaryNameNode 4278 NameNode 4889 Jps

#### 12. 停止HDFS和MapReduce

 执行以下命令启动HDFS和MapReduce [hadoop@ Master ~]\$ stop-all.sh

#### 13. 运行测试

• 在Linux文件系统下(如/root/test)创建两个文本数据文件:

file1.txt: hello hadoop hello world

file2.txt: goodbye hadoop

• 将文件复制到HDFS文件系统中:

[hadoop@ Master ~]\$ dfs -copyFromLocal /root/test test-in

test-in是在HDFS中建立的一个数据数据目录

运行hadoop安装包中自带的WorldCount程序进行测试:

[hadoop@ Master ~]\$ hadoop jar hadoop-0.21.0-examples.jar wordcount test-in test-out

其中test-out只能由程序创建,不能事先存在

程序开发与提交作业基本过程 Hadoop Cluster-1.在本地编写 程序与调试 Master 3在集群上完 2上传程 成计算作业 序与数据 Jser

#### 1. 本地完成程序编写和调试

在自己本地安装了单机或伪分布Hadoop系统的机器上,完成程序编写和调试

#### 2.创建用户账户

为了能访问Hadoop集群提交作业,需要为每个程序用户创建一个账户,获取用户名、密码等信息。

#### 3.将数据和程序传送到Hadoop集群

• 准备好数据和程序目录 例如:

```
me@local:~/workspace$ Is -R wordcount
wordcount:
wordcount.jar
wordcount/files: file01.txt_file02.txt
```

• 用scp命令传送至Hadoop平台主机上:

```
me@local:~/workspace$ scp -r wordcount
```

username@Master:workspace/wordcount

username@ Master's password: [在此输入您的密码]

#### 4.用SSH命令远程登录到Hadoop集群

me@local:~/workspace\$ ssh username@Master username@Master's password: [在此输入您的密码]

#### 5.将数据复制到HDFS中

• 进入到程序包所在目录:

username@Master:~\$ cd workspace/wordcount username@Master:~/workspace/wordcount\$ Is files wordcount.jar

 用hadoop dfs –put命令将数据从Linux文件系统中复制到HD FS:

username@Master:~/workspace/wordcount\$ hadoop dfs -put files test-in

#### 6.用hadoop jar命令向Hadoop提交计算作业

username@Master:~/workspace/wordcount\$

hadoop jar wordcount.jar test-in test-out

这里的test-in为被统计的文本文件的目录,test-out为指定的输出结果的目录,注意test-out目录事先不能存在,若存在需要先删除。

#### 7. 查看运行结果

• 查看test-out目录,统计结果被输出到文件test-out/part-r-00000中

username@Master:~/workspace/wordcount\$ hadoop dfs -ls test-out Found 2 items

drwxr-xr-x - hadoopusr supergroup 0 2010-05-23 20:29 /user/hadoopusr/test-out/\_logs -rw-r--r- 1 hadoopusr supergroup 35 2010-05-23 20:30 /user/hadoopusr/test-out/part-r-00000

• 查看计算结果

username@Master:~/workspace/wordcount\$ hadoop dfs -cat test-out/part-r-00000

GoodBye 1

Hadoop 2 Hello 2 World

也可以把文件从HDFS中复制到Linux文件系统中查看

username@Master:~/workspace/wordcount\$ hadoop dfs -get test-out/part-r-00000 test-out.txt username@Master:~/workspace/wordcount\$ vi test-out.txt

GoodBye 1

Hadoop 2 Hello 2 World 1

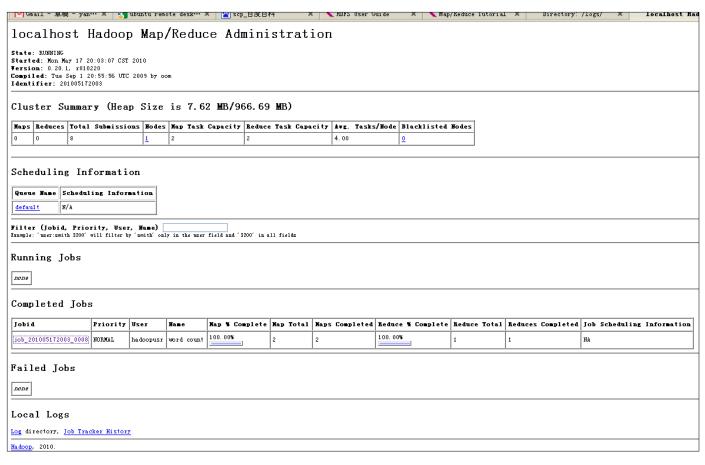
### 8. 用Hadoop的Web界面查看Hadoop集群和作业状态

• 在浏览器中打开http:// NameNode节点IP:50070/. 可看到集群的基本信息

```
NameNode 'Ubuntu10:54310'
  Started:
               Mon May 17 20:02:54 CST 2010
  Version:
               0.20.1, r810220
  Compiled:
               Tue Sep 1 20:55:56 UTC 2009 by oom
  Upgrades:
               There are no upgrades in progress.
Browse the filesystem
Namenode Logs
Cluster Summary
24 files and directories, 7 blocks = 31 total. Heap Size is 7.62 MB / 966.69 MB (0%)
  Configured Capacity :
                            11.27 GB
  DFS Used
                             112 KB
  Non DFS Used
                             3.79 GB
  DFS Remaining
                             7.47 GB
  DFS Used%
                                 0 %
  DFS Remaining%
                             66.33 %
  Live Nodes
                                   1
  Dead Nodes
NameNode Storage:
 Storage Directory
                               Type
                                               State
 /home/hadoopusr/hadoop/dfs/name
                               IMAGE_AND_EDITS
                                               Active
Hadoop, 2010.
```

### 8. 用Hadoop的Web界面查看Hadoop集群和作业状态

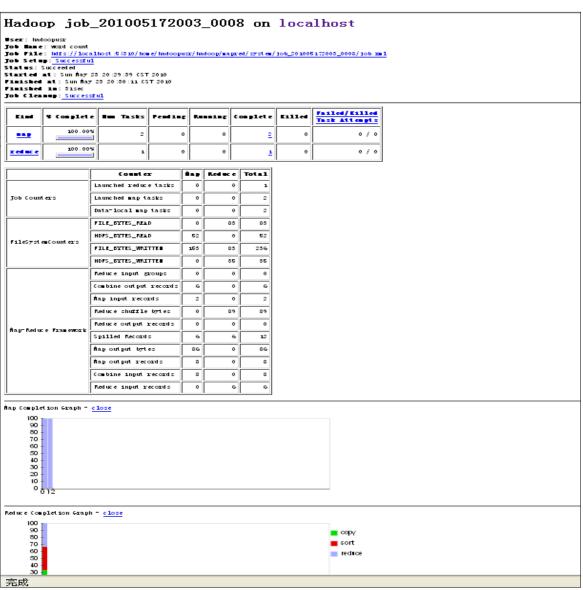
打开页面中的Namenode Logs链接,可以查看到大量的日志文件,每个都可以打开查看其内容



8.用Hadoop的Web 界面查看Hadoop 集群和作业状态

http:// NameNode节点IF :50030/

点击一个作业可以查看作业的详细信息



# 实验1:安装单机Hadoop系统

#### 实验内容与要求

- 1. 每人在自己本地电脑上正确安装和运行伪分布式 Hadoop系统。
- 2. 安装完成后,自己寻找一组英文网页数据,在本机上运行Hadoop系统自带的WordCount可执行程序文件,并产生输出结果
- 3. 实验结果提交:要求书写一个实验报告,其中包括:
  - 1. 系统安装运行的情况
  - 2. 实验数据说明(下载的什么网页数据,多少个HTML或text文件)
  - 3. 程序运行后在Hadoop Web作业状态查看界面上的作业运行状态屏幕拷贝
  - 4. 实验输出结果开头部分的屏幕拷贝
  - 5. 实验体会

# Thanks!